

**ПРАВИТЕЛЬСТВО РОССИЙСКОЙ ФЕДЕРАЦИИ
ФГАОУ ВО НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»**

Факультет компьютерных наук
Образовательная программа «Прикладная математика и информатика»

УДК: 612.8:[004.93+515.1]

Отчет об исследовательском проекте

на тему: Анализ аффективных компонентов ЭЭГ при прослушивании музыки

Выполнил:

Студент группы БПМИ207



Подпись

А.С.Петелин

И.О.Фамилия

18.05.2022

Дата

Принял:

Руководитель проекта

Всеволод Леонидович Чернышев

Имя, Отчество, Фамилия

доцент, к.ф.-м.н.

Должность, ученое звание

ФКН НИУ ВШЭ, Департамент больших данных и информационного поиска

Место работы (Компания или подразделение НИУ ВШЭ)

Дата проверки 21.05.2022

7 баллов (хорошо)

Оценка (по 10-ти бальной шкале)



Подпись

Москва 2022

Содержание

1	Основные термины и определения	2
2	Введение	2
3	Обзор используемых источников	3
4	Данные и методы	4
4.1	Модули Python	4
4.2	DEAP	4
4.3	Модель эмоций	5
5	Работа с данными	6
5.1	Извлечение признаков	6
5.1.1	Мощности частотных диапазонов	6
5.1.2	Статистические характеристики	7
5.1.3	Параметры Хьюрта	7
5.1.4	Фрактальная размерность	8
5.2	Классификация	8
5.3	Применение PCA	8
6	Полученные результаты	9
6.1	Сравнение результатов классификации с использованием PCA - секция 5.4	9
6.2	Рассуждения	9
7	Список литературы	9

1 Основные термины и определения

Электроэнцефалограмма (далее **ЭЭГ/EEG**) – один из методов, позволяющих провести исследование головного мозга человека; в основе метода лежит регистрация электрических импульсов от мозга или каких-то его отдельных областей с помощью специального прибора.

Центральная нервная система (далее **ЦНС**) – совокупность связанных между собой нейронов, у человека представлена головным и спинным мозгом.

Отбор признаков / Feature Selection (далее **FS**) – это оценка значимости признаков модели с помощью алгоритмов машинного обучения с целью сокращения размерности исследуемого пространства.

Метод главных компонент / Principle Component Analysis (далее **PCA**) – один из основных методов уменьшения размерности данных при минимизации потерь содержащейся в данных информации.

Метод k-ближайших соседей / k-nearest neighbors (далее **k-NN**) – метрический алгоритм для автоматической классификации объектов или регрессии, основанный на оценивании сходства объектов.

Метод опорных векторов / Support Vector Machine (далее **SVM**) – набор схожих алгоритмов обучения с учителем, использующихся для задач классификации и регрессионного анализа.

Многослойный перцептрон / Multilayered perceptron (далее **MLP**) – класс искусственных нейронных сетей, применимый в задачах классификации.

Циркумplexная модель эмоций – предполагает, что эмоции распределяются в двумерном круговом пространстве, содержащем измерения возбуждения и привлекательности(валентности).

Кросс-валидация – метод оценки аналитической модели и её поведения на независимых данных, основывающийся на разбиении данных на k частей.

Dataset / Data Set – (размеченный) набор данных в табличном виде.

DEAPdataset [1], [2] – датасет для анализа эмоций с данными ЭЭГ, физиологических и видеосигналов.

2 Введение

Влияние музыки на слушателей отражено во многих источниках, как в художественных, так и в научных. Так, исследования показывают, что музыка помогает облегчить боль [3], влияет на координацию движений [4] [5]

и темпы дыхания [6]. Также одним из важнейших свойств музыки является её способность влиять на эмоциональное состояние человека [7]. Вопрос влияния на эмоциональное состояние человека является одним из ключевых при разработке систем взаимодействия человека и компьютера, более того, подбор подходящей музыки может улучшить состояние отдельного человека при использовании музыкального приложения [8]. Примером компании, основавшей на этом позитивном изменении свою бизнес модель, является Endel [9], разрабатывавшая одноимённое приложение. Приложение предлагает персонализированные аудиотреки, которые “помогут сосредоточиться, расслабиться и уснуть”.

Возрастающий интерес к музыкальной сфере как со стороны бизнеса, так и со стороны отдельных пользователей, позволяет говорить об актуальности изучения взаимодействия человека и музыки. Таким образом, можно поставить задачу распознавания влияния музыки на эмоциональное состояние человека.

Для изучения влияния музыки прежде всего необходимо его измерить. В настоящий момент существует несколько технологий для фиксирования изменений эмоций, среди которых распознавание эмоций по мимике (facial recognition), изучение периферийных физиологических сигналов, а также сигналов мозга. В данном исследовании мы сосредоточимся на изучении данных о сигналах мозга, полученных с помощью ЭЭГ. Стоит отметить, что характеристики ЭЭГ содержат множество нелинейных зависимостей [10], что позволяет в дальнейшем поставить вопрос об эффективности различных алгоритмов анализа данных.

При переходе от этапа сбора данных к оцениванию, исследователи сталкиваются с рядом вопросов: как разбить данные? как сократить их размерность? каким образом классифицировать данные? Для решения этих проблем в машинном обучении существует множество подходов, одним из которых является PCA.

Метод PCA основан на поиске в исходном пространстве признаков гиперплоскости заданной размерности с последующим проектированием выборки на данную гиперплоскость. При этом выбирается та гиперплоскость, ошибка проектирования данных на которую является минимальной в смысле суммы квадратов отклонений. Метод позволяет не только сократить количество ключевых признаков, но и построить доступные проекции для оценки свойств данных. При анализе данных ЭЭГ используется множество признаков, в связи с чем исследователи сталкиваются со значительным увеличением веса модели и времени её обучения, иногда сталкиваясь с проклятием размерности [11]. В таких условиях использование методов снижения размерности данных особенно важно. В данной работе будет рассмотрен алгоритм распознавания эмоций на основе датасета DEAP и продемонстрирована эффективность использования PCA при работе с большим количеством признаков. В соответствии с поставленной задачей можно выделить следующие цели исследования:

1. Подготовить данные на основе датасета DEAP;
2. Построить набор классификаторов для предсказания эмоций в циркумplexной модели эмоций;
3. Использовать PCA как алгоритм FS для сокращения размерности пространства данных и выделения ключевых признаков будущей модели;
4. Сравнить эффективность использования классификаторов на исходной выборке и выборке, подвергнутой алгоритму PCA.

Корректное использование метода PCA при анализе ЭЭГ позволит в дальнейшем получить преимущество как при исследованиях, так и при разработке музыкальных сервисов.

3 Обзор используемых источников

Работа основана на исследовании открытого датасета DEAP, содержащего данные ЭЭГ и некоторые другие сведения, позволяющие изучать эмоции человека во время прослушивания музыки [1]. Сравнение некоторых алгоритмов отбора признаков, в том числе и PCA, для распознавания эмоций уже приведено в статье [12], более того, авторы статей [13], [14] рассказывают ещё больше об исследовании данных ЭЭГ. Ряд авторов [15], [16] использует мультимодальные нейронные сети для достижения высокой точности предсказаний (state-of-art). Отдельные исследователи [17] применяют комбинацию качественного отбора признаков и необычного классификатора для повышения точности предсказаний на датасете DEAP. Представленные выше работы тесно связаны и находятся на переднем краю исследований в области анализа EEG данных, что предлагает серьёзную основу для данного исследования.

4 Данные и методы

4.1 Модули Python

Работа велась с использованием jupyter notebook [18] (далее ноутбук), в который были загружены следующие библиотеки и модули:

1. Pandas – для использования Dataframe, объекта для манипулирования индексированными массивами двумерных данных;
2. Seaborn и Matplotlib – необходимые модули для визуализации данных, построения графиков;
3. Scipy – импортируются функции для работы с данными ЭЭГ и математических преобразований, одна из ключевых функций – `signal.welch`, позволяющая оценивать спектральную плотность сигнала с помощью метода Уэлча [19].
4. Sklearn – включает ключевые инструменты анализа данных, используемые в дальнейшем методы PCA, SVC, k-NN и MLP, а также метрики оценки качества обработки данных и построения классификаторов;
5. MNE – используются модули для визуализации и кросс-валидации.

Все используемые модули, включая стандартные, можно увидеть в секции 1.1. ноутбука.

4.2 DEAP

В проекте используются данные датасета DEAP, предназначенного для распознавания эмоций с использованием данных ЭЭГ, физиологических и видеосигналов. С помощью специальных электродов, эти данные измерялись для 32 участников, каждый из которых посмотрел 40 одноминутных отрывков музыкальных клипов. Также участники оценивали каждый клип с точки зрения уровней возбуждения, валентности, доминирования и знакомства – характеристик важных для распознавания эмоций, более подробно описанных в разделе Модель эмоций.

Стоит отметить, что данные датасета, используемые в проекте, уже прошли первичную обработку, в ходе которой были убраны артефакты и часть шумов. Чтобы получить доступ к данным, необходимо обратиться к авторам датасета на указанном выше сайте. В проект не включены данные датасета в соответствии с соглашением EULA, однако результаты работы можно воспроизвести, загрузив данные `data_preprocessed_python.zip` в папку `project_data`.

Загрузка датасета происходит в секции 1.2. ноутбука. В данном проекте используются только данные с 32 датчиков ЭЭГ, а также шкалы Возбуждения(Arousal) и Валентности(Valence), выделение которых соответствует секциям 2.1. - 2.2. ноутбука.

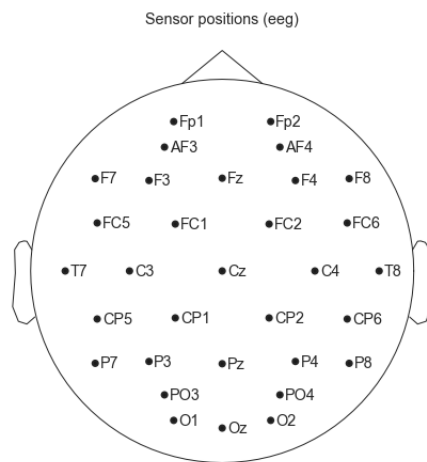


Рис. 1: Расположение датчиков на голове человека

4.3 Модель эмоций

Исследование опирается на использование циркумплексной модели эмоций, предложенной Джеймсом Расселом [20]. Модель основывается на распределении эмоций в двумерном круговом пространстве, содержащем измерения возбуждения и валентности. Возбуждение представляет собой вертикальную ось, а валентность представляет собой горизонтальную ось, а центр круга представляет нейтральную валентность и средний уровень возбуждения. Различные чёткие эмоции могут быть нанесены на циркумплекс в соответствии с их уровнями возбуждения и валентности.




Рис. 2: Четкие эмоции на циркумплексе Рассела [21]

В исследовании показатели возбуждения и валентности кодируются бинарно относительно медианы измерений. Таким образом, каждый прослушанный клип имеет бинарный рейтинг по каждой шкале, что позволяет сформировать 4 категории эмоций, соответствующих четвертям циркумплекса:

1. Высокое Возбуждение, Высокая Валентность / High Arousal High Valence (далее HAHV)
2. Низкое Возбуждение, Высокая Валентность / Low Arousal High Valence (далее LAHV)
3. Высокое Возбуждение, Низкая Валентность / High Arousal Low Valence (далее HALV)
4. Низкое Возбуждение, Низкая Валентность / Low Arousal Low Valence (далее LALV)

Эти категории также добавлены в датафрейм и закодированы в секции 2.1. ноутбука, распределение возбуждения и валентности в четвертях циркумплекса можно наблюдать на изображении ниже.




Рис. 3: Распределение Возбуждения(Arousal) и Валентности(Valence) относительно четвертей циркумплекса

5 Работа с данными

5.1 Извлечение признаков

Как уже было отмечено, в исследовании рассматриваются только данные 32 датчиков ЭЭГ для каждого клипа. В соответствии с этим, для каждого сигнала можно выделить следующие категории признаков:

1. Мощности частотных диапазонов;
2. Статистические характеристики;
3. Параметры Хьюрта [22];
4. Фрактальная размерность.

Опишем введённые параметры.

5.1.1 Мощности частотных диапазонов

Рассмотрим сырые данные из датасета.




Рис. 4: Сигнал

Как можно понять по графику, на протяжении времени измеряется только напряжение. Однако напряжения недостаточно для характеристики мозговых волн, в связи с чем вводится дополнительная характеристика – спектральная плотность мощности. СПМ – функция, описывающая распределение мощности сигнала в зависимости от частоты. Её можно вычислить методом Уэлча[19]. Пример вычисления такой характеристики для отдельного сигнала можно увидеть на изображении ниже.

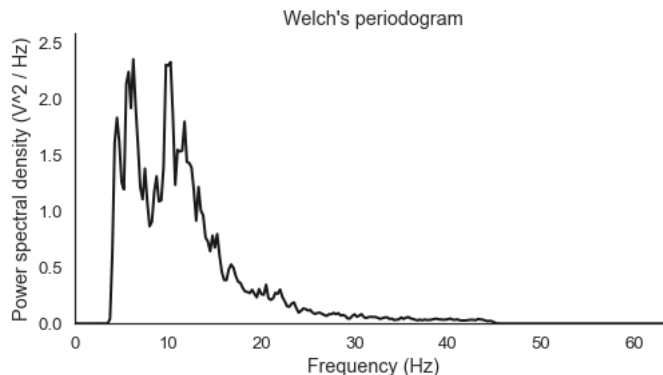


Рис. 5: Периодограмма Уэлча

Однако напрямую данная характеристика в исследовании не будет использоваться, но понадобится для вычисления средней мощности входного сигнала (bandpower), которую мы вычислим для каждого диапазона частот мозга.

При передаче электрических импульсов по нервным волокнам от нейрона к нейрону мозг человека генерирует волны, называемые мозговыми. Они принимают значения от 1 до 70 Гц и выше и подразделяются на следующие категории:

Название диапазона	Принимаемые значения
Дельта-волны	1 - 4 Гц
Тета-волны	4 - 8 Гц
Альфа-волны	8 - 12 Гц
Бета-волны	12 - 30 Гц
Гамма-волны	30 - 70 Гц

Стоит отметить, что датчики не замеряли дельта-волны, а гамма-волны были ограничены сверху в 64 Гц. После разбиения частот на диапазоны для каждого из 4 диапазонов (дельта, тета, альфа и гамма) необходимо вычислить соответствующую мощность сигнала. Вычисление реализовано на основе алгоритма, предложенного Raphael Vallat[23].

5.1.2 Статистические характеристики

Изначально предполагалось использование 6 характеристик – функций от массива значений напряжения конкретного электрода: медиана, среднее, максимальное и минимальное значение, стандартное отклонение и коэффициент эксцесса (Куртосис). Однако в ходе работы я ограничился тремя из них:

1. Среднее (арифметическое) – мера центральной тенденции, равная сумме всех чисел множества, делённой на их количество:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \frac{1}{n} (x_1 + \dots + x_n)$$

2. Стандартное отклонение – мера величины вариации или дисперсии набора значений. Определяется как корень из дисперсии случайной величины:

$$\sigma = \sqrt{D[X]}$$

3. Куртосис – мера остроты пика распределения случайной величины. Определяется следующим образом для случайной величины X , такой что $\mathbb{E}|X|^4 < \infty$. Пусть μ_4 обозначает четвёртый центральный момент X , а σ – стандартное отклонение X , тогда куртосис вычисляется как

$$\gamma_2 = \frac{\mu_4}{\sigma^4} - 3$$

5.1.3 Параметры Хьюрта

Данные параметры были предложены Бо Хьюртом [22] для исследования данных ЭЭГ, на эти признаки опирались некоторые представленные в библиографии статьи.

1. Активность – представляет мощность сигнала, дисперсию временной функции:

$$\text{Activity} = \text{var}(y(t))$$

2. Мобильность – представляет собой среднюю частоту или долю стандартного отклонения спектра мощности и определяется как квадратный корень из дисперсии первой производной сигнала, деленной на дисперсию сигнала:

$$\text{Mobility} = \sqrt{\frac{\text{var}\left(\frac{dy(t)}{dt}\right)}{\text{var}(y(t))}}$$

3. Сложность – представляет изменение частоты и выражается следующим образом:

$$\text{Complexity} = \frac{\text{Mobility}\left(\frac{dy(t)}{dt}\right)}{\text{Mobility}(y(t))}$$

5.1.4 Фрактальная размерность

Используется параметр фрактальной размерности, предложенный А.Петросяном [24] и вычисляющийся как

$$P = \frac{\log_{10}(N)}{\log_{10}(N) + \log_{10}(\frac{N}{N+0.4N_{\delta}})}$$

где N – длина сигнала, а N_{δ} является числом изменений знака в производной сигнала.

Помимо введённых параметров, в исследованиях ЭЭГ также используются другие характеристики, такие как логарифмические мощности частотных диапазонов [25] и Вейвлет-преобразование [26].

Вычислив параметры в секции 3.1. ноутбука, был получен датафрейм, содержащий 11 характеристик каждого из 32 сигналов, всего 352 признака.

	Theta_01	Alpha_01	Beta_01	Gamma_01	Mean_01	...	Kurtosis_32	Activity_32	Mobility_32	Complexity_32	Fractal dimension_32
0	3.966387	3.362791	5.815234	1.216603	-0.028259	...	0.423327	19.153627	0.550910	1.279431	1.014171
1	5.171664	4.159797	6.395374	1.450174	-0.082712	...	0.636155	23.840406	0.524440	1.312275	1.014451
2	4.839268	4.294426	6.721424	1.541999	0.060689	...	0.917153	26.850180	0.547663	1.260934	1.014610
3	4.442888	3.519818	5.380133	1.280744	-0.027773	...	0.515875	22.089439	0.531993	1.286845	1.014051
4	2.698928	2.770151	4.911636	1.076200	-0.062537	...	0.552951	17.434434	0.568176	1.236513	1.014226

Рис. 6: Фрагмент датафрейма

5.2 Классификация

Нас будет интересовать задача классификации клипов по типу вызываемых эмоций. В фокусе внимания находится предсказание возбуждения (высокого или низкого), валентности (высокой или низкой), а также четверти циркумплекса (HANV, LANV, HALV, LALV) в предложенной ранее модели эмоций. Для обработки полученного набора признаков будем разбивать данные на тренировочную и тестовую выборки, а затем проводить Масштабирование признаков (Feature Scaling) как предложено в секции 5.1 ноутбука. Масштабирование признаков помогает нормализовать выборку, что существенно для работы некоторых классификаторов. Далее используем несколько классификаторов, применив подход кросс-валидации с 5-кратной проверкой (kFold=5). В проекте использованы классификаторы SVM, k-NN и MLP.

Будем отслеживать точность предсказаний для 3 признаков, упомянутых выше: Arousal(1, 0), Valence(1, 0) и State(HANV, LANV, HALV, LALV). После описанной процедуры были получены следующие точности(секция 3.2 ноутбука):

- Точность для Arousal: 64.23;
- Точность для Valence: 67.48;
- Точность для State: 43.9.

Несмотря на точность, сопоставимую с результатами статьи [17], с помощью применения PCA можно добиться улучшения точности.

5.3 Применение PCA

Как в предыдущем случае, сначала произведём масштабирование признаков (секция 4.1 ноутбука), так как оно существенно для корректной работы алгоритма PCA. Затем напомним функцию, которая будет использовать PCA с заданным числом компонент(секция 4.2 ноутбука). Чтобы вычислить оптимальное число компонент, применим PCA для всех размеров компонент в диапазоне от 2 до 75 (до четверти от исходного количества признаков – 352). После каждого применения PCA применим функцию для измерения точности предсказания с предложенными классификаторами из пункта выше и построим график, сопоставляющий число компонент PCA с точностью предсказаний (секция 5.3 ноутбука).




Рис. 7: Применение PCA для предсказания Arousal, Valence и State

По графику видно, что даже при малом числе компонент можно добиться высокой точности модели. В соответствии с графиком выберем небольшое, оптимальное число компонент и оценим точность предсказаний.

- Улучшение точности предсказания для Arousal после PCA: 64.23 -> 69.11 . Всего: + 4.88%;
- Улучшение точности предсказания для Valence после PCA: 67.48 -> 73.17 . Всего: + 5.69%;
- Улучшение точности предсказания для State после PCA: 43.9 -> 49.59 . Всего: + 5.69%.

Также можно оценить снижение количества компонент

- Достигнутая точность для Arousal: 69.11 . Снижение числа компонент: 352 -> 12;
- Достигнутая точность для Valence: 73.17 . Снижение числа компонент: 352 -> 30;
- Достигнутая точность для State: 49.59 . Снижение числа компонент: 352 -> 59.

6 Полученные результаты

6.1 Сравнение результатов классификации с использованием PCA - секция 5.4

Рассмотрев полученные результаты (секция 5.4 ноутбука), можно выявить преимущества использования PCA над выборкой перед классификацией. Прежде всего, это многократное сокращение количества признаков, необходимых для точной работы модели. Более того, в результате преобразований были получены такие признаки, что точность модели даже повысилась (в среднем, на 5 процентных пунктов). Это может свидетельствовать о применимости PCA в очистке шума и лишних признаков, которые могли ухудшать качество модели. При исследованиях ЭЭГ как сокращение количества признаков модели, так и очистка шума являются важными задачами. Проведённое исследование демонстрирует эффективность PCA в решении этих задач и доказывает применимость PCA в повышении точности модели и сокращения её веса.

6.2 Рассуждения

Тем не менее, существуют другие способы отбора признаков, например, в уже упомянутой статье [17] используется алгоритм Максимальной релевантности – минимальной избыточности / Maximum Relevance – Minimum Redundancy(MRMR) и достигаются аналогичные результаты. Некоторые исследователи используют Анализ независимых компонент / Independent component analysis (ICA) для отбора признаков модели. Более того, на передний план выходит необходимость выявления нелинейных зависимостей признаков [10], для чего PCA неприменима, в связи с чем используются модели, основанные на глубоких нейронных сетях. Использование мультимодальных нейронных сетей было успешно в статьях [15], [16], являющиеся state-of-the-art работами, основанными также на данных DEAP. Все указанные способы отбора признаков отличаются от рассмотренного в исследовании, что позволяет говорить о необходимости выявления наиболее оптимальных подходов в будущем.

7 Список литературы

- [1] S. Koelstra, C. Muhl, M. Soleymani, Jong-Seok Lee, A. Yazdani, T. Ebrahimi, T. Pun, A. Nijholt, and I. Patras. Deap: A database for emotion analysis using physiological signals. *IEEE Transactions on Affective Computing*, 3(1):18–31, 2012.

- [2] Deapdataset. <http://www.eecs.qmul.ac.uk/mmv/datasets/deap/>. Дата обращения: Март 10, 2022, доступ регулируется EULA.
- [3] Joseph Newbold, Nadia Bianchi-Berthouze, Nicolas Gold, and Amanda Williams. Musically informed sonification for self-directed chronic pain physical rehabilitation, 06 2015. Conference: Sound and Music Computing 2015.
- [4] Bruno H. Repp. Sensorimotor synchronization: a review of the tapping literature. *Psychonomic Bulletin & Review*, 12(6):969–992, 2005.
- [5] Gisa Aschersleben. Temporal control of movements in sensorimotor synchronization. *Brain and Cognition*, 48(1):66–79, 2002.
- [6] J. Berger D. Siwiak and Y. Yang. Catch your breath-musical biofeed- back for breathing regulation, 2009. Conference: Audio Eng. Society Conv 2009.
- [7] S. Koelsch. *Brain and Music*, pages 179–180. Wiley, 2012.
- [8] Grace Leslie, Asma Ghandeharioun, Diane Y. Zhou, and Rosalind W. Picard. Engineering music to slow breathing and invite relaxed physiology. *2019 8th International Conference on Affective Computing and Intelligent Interaction (ACII)*, pages 1–7, 2019.
- [9] Endel: Personalized soundscapes to help you focus, relax, and sleep. backed by neuroscience. <https://endel.io/>. Дата обращения: Feb 10, 2022, открытый доступ.
- [10] Xiao-Wei Wang, Dan Nie, and Bao-Liang Lu. Emotional state classification from eeg data using machine learning approach. *Neurocomputing*, 129:94–106, 2014.
- [11] Warren B Powell. Approximate dynamic programming : solving the curses of dimensionality, 2011.
- [12] Rab Nawaz, Kit Hwa Cheah, Humaira Nisar, and Vooi Voon Yap. Comparison of different feature extraction methods for eeg-based emotion recognition. *Biocybernetics and Biomedical Engineering*, 40(3):910–926, 2020.
- [13] Avinash L. Tandle, Manjusha S. Joshi, Ambrish S. Dharmadhikari, and Suyog V. Jaiswal. Mental state and emotion detection from musically stimulated eeg. *Brain Informatics*, 5(2):14, 2018.
- [14] Klaus Scherer. Which emotions can be induced by music? what are the underlying mechanisms? and how can we measure them? *Journal of New Music Research*, 33:239–251, 09 2004.
- [15] Yuxuan Zhao, Xinyan Cao, Jinlong Lin, Dunshan Yu, and Xixin Cao. Multimodal emotion recognition model using physiological signals. *ArXiv*, abs/1911.12918, 2019.
- [16] Wei Liu, Wei-Long Zheng, and Bao-Liang Lu. Multimodal emotion recognition using multimodal deep learning. pages 1–7, 02 2016.
- [17] John Atkinson-Abutridy and Daniel Campos. Improving bci-based emotion recognition by combining eeg feature selection and kernel classifiers. *Expert Systems with Applications*, 47, 11 2015.
- [18] Jupyter notebook. <https://jupyter.org/>. 2022.
- [19] P. Welch. The use of fast fourier transform for the estimation of power spectra: A method based on time averaging over short, modified periodograms. *IEEE Transactions on Audio and Electroacoustics*, 15(2):70–73, 1967.
- [20] James Russell. A circumplex model of affect. *Journal of Personality and Social Psychology*, 39:1161–1178, 12 1980.
- [21] Cristina de balanzo, rafal ohme, and Henk Eising. Predicting brand decisions through emotional engagement, 09 2011.
- [22] Bo Hjorth. EEG analysis based on time domain properties. *Electroencephalography and Clinical Neurophysiology*, 29(3):306–310, 1970.

- [23] Compute the average bandpower of an eeg signal. <https://raphaelvallat.com/bandpower>. Дата обращения: Май 10, 2022, в открытом доступе.
- [24] Arthur A. Petrosian. Kolmogorov complexity of finite sequences and recognition of different preictal eeg patterns. *Proceedings Eighth IEEE Symposium on Computer-Based Medical Systems*, pages 212–217, 1995.
- [25] Clemens Brunner, Martin Billinger, Carmen Vidaurre, and Christa Neuper. A comparison of univariate, vector, bilinear autoregressive, and band power features for brain–computer interfaces. *Medical biological engineering computing*, 49:1337–46, 09 2011.
- [26] Panagiotis Petrantonakis and Leontios Hadjileontiadis. Emotion recognition from brain signals using hybrid adaptive filtering and higher order crossings analysis. *Affective Computing, IEEE Transactions on*, 1:81–97, 07 2010.

Приложение А. Цифровые материалы

Ноутбук, а также .tex файлы для формирования документа и иллюстрации можно найти на <https://github.com/chmousNedovolnii/ResearchProject>.