

**ПРАВИТЕЛЬСТВО РОССИЙСКОЙ ФЕДЕРАЦИИ  
ФГАОУ ВО НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ  
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»**

Факультет компьютерных наук  
Образовательная программа «Прикладная математика и информатика»

УДК: 612.8:[004.93+515.1]

**Отчет об исследовательском проекте**

на тему: Анализ аффективных компонентов ЭЭГ при прослушивании музыки

**Выполнил:**

Студент группы БПМИ207



Подпись

А.С.Петелин

И.О.Фамилия

18.05.2022

Дата

**Принял:**

Руководитель проекта

Всеволод Леонидович Чернышев

Имя, Отчество, Фамилия

доцент, к.ф.-м.н.

Должность, ученое звание

ФКН НИУ ВШЭ, Департамент больших данных и информационного поиска

Место работы (Компания или подразделение НИУ ВШЭ)

Дата проверки

2022

Оценка (по 10-ти бальной шкале)

Подпись

Москва 2022

# Содержание

1	Основные термины и определения	2
2	Введение	3
3	Обзор используемых источников	3
4	Данные и методы	4
4.1	Модули Python . . . . .	4
4.2	DEAP - секция 1.2 . . . . .	4
4.3	Модель эмоций . . . . .	5
5	Работа с данными	6
5.1	Извлечение признаков . . . . .	6
5.1.1	Мощности частотных диапазонов . . . . .	6
5.1.2	Статистические характеристики . . . . .	7
5.1.3	Параметры Хьорта . . . . .	7
5.1.4	Фрактальная размерность . . . . .	8
5.2	Классификация . . . . .	8
5.3	Применение PCA . . . . .	8
6	Полученные результаты	9
6.1	Сравнение результатов классификации с использованием PCA - секция 5.4 . . . . .	9
6.2	Рассуждения . . . . .	9
7	Список литературы	9
	Приложение А. Календарный план работ	11

## 1 Основные термины и определения

**Электроэнцефалограмма** (далее **ЭЭГ/EEG**) – один из методов, позволяющих провести исследование головного мозга человека; в основе метода лежит регистрация электрических импульсов от мозга или каких-то его отдельных областей с помощью специального прибора.

**Центральная нервная система** (далее **ЦНС**) – совокупность связанных между собой нейронов, у человека представлена головным и спинным мозгом.

**Отбор признаков / Feature Selection** (далее **FS**) – это оценка значимости признаков модели с помощью алгоритмов машинного обучения с целью сокращения размерности исследуемого пространства.

**Метод главных компонент / Principle Component Analysis** (далее **PCA**) – один из основных методов уменьшения размерности данных при минимизации потерь содержащейся в данных информации.

**Метод k-ближайших соседей / k-nearest neighbors** (далее **k-NN**) – метрический алгоритм для автоматической классификации объектов или регрессии, основанный на оценивании сходства объектов.

**Метод опорных векторов / Support Vector Machine** (далее **SVM**) – набор схожих алгоритмов обучения с учителем, использующихся для задач классификации и регрессионного анализа.

**Многослойный перцептрон / Multilayered perceptron** (далее **MLP**) – класс искусственных нейронных сетей, применимый в задачах классификации.

**Циркумplexная модель эмоций** – предполагает, что эмоции распределяются в двумерном круговом пространстве, содержащем измерения возбуждения и привлекательности(валентности).

**Кросс-валидация** – метод оценки аналитической модели и её поведения на независимых данных, основывающийся на разбиении данных на k частей.

**Datасet / Data Set** – (размеченный) набор данных в табличном виде.

**DEAPdataset** [1], [2] – датасет для анализа эмоций с данными ЭЭГ, физиологических и видеосигналов.

## 2 Введение

Влияние музыки на слушателей отражено во многих источниках, как в художественных, так и в научных. Так, исследования показывают, что музыка помогает облегчить боль [3], влияет на координацию движений [4] [5] и темпы дыхания [6]. Также одним из важнейших свойств музыки является её способность влиять на эмоциональное состояние человека [7]. Вопрос влияния на эмоциональное состояние человека является одним из ключевых при разработке систем взаимодействия человека и компьютера, более того, подбор подходящей музыки может улучшить состояние отдельного человека при использовании музыкального приложения [8]. Примером компании, основавшей на этом позитивном изменении свою бизнес модель, является Endel [9], разрабатывавшая одноимённое приложение. Приложение предлагает персонализированные аудиотреки, которые “помогут сосредоточиться, расслабиться и уснуть”.

Возрастающий интерес к музыкальной сфере как со стороны бизнеса, так и со стороны отдельных пользователей, позволяет говорить об актуальности изучения взаимодействия человека и музыки. Таким образом, можно поставить задачу распознавания влияния музыки на эмоциональное состояние человека.

Для изучения влияния музыки прежде всего необходимо его измерить. В настоящий момент существует несколько технологий для фиксирования изменений эмоций, среди которых распознавание эмоций по мимике (facial recognition), изучение периферийных физиологических сигналов, а также сигналов мозга. В данном исследовании мы сосредоточимся на изучении данных о сигналах мозга, полученных с помощью ЭЭГ. Стоит отметить, что характеристики ЭЭГ содержат множество нелинейных зависимостей [10], что позволяет в дальнейшем поставить вопрос об эффективности различных алгоритмов анализа данных.

При переходе от этапа сбора данных к оцениванию, исследователи сталкиваются с рядом вопросов: как разбить данные? как сократить их размерность? каким образом классифицировать данные? Для решения этих проблем в машинном обучении существует множество подходов, одним из которых является PCA.

Метод PCA основан на поиске в исходном пространстве признаков гиперплоскости заданной размерности с последующим проектированием выборки на данную гиперплоскость. При этом выбирается та гиперплоскость, ошибка проектирования данных на которую является минимальной в смысле суммы квадратов отклонений. Метод позволяет не только сократить количество ключевых признаков, но и построить доступные проекции для оценки свойств данных. При анализе данных ЭЭГ используется множество признаков, в связи с чем исследователи сталкиваются со значительным увеличением веса модели и времени её обучения, иногда сталкиваясь с проклятием размерности [11]. В таких условиях использование методов снижения размерности данных особенно важно. В данной работе будет рассмотрен алгоритм распознавания эмоций на основе датасета DEAP и продемонстрирована эффективность использования PCA при работе с большим количеством признаков. В соответствии с поставленной задачей можно выделить следующие цели исследования:

1. Подготовить данные на основе датасета DEAP;
2. Построить набор классификаторов для предсказания эмоций в циркумplexной модели эмоций;
3. Использовать PCA как алгоритм FS для сокращения размерности пространства данных и выделения ключевых признаков будущей модели;
4. Сравнить эффективность использования классификаторов на исходной выборке и выборке, подвергнутой алгоритму PCA.

Корректное использование метода PCA в при анализе ЭЭГ позволит в дальнейшем получить преимущество как при исследованиях, так и при разработке музыкальных сервисов.

## 3 Обзор используемых источников

Работа основана на исследовании открытого датасета DEAP, содержащего данные ЭЭГ и некоторые другие сведения, позволяющие изучать эмоции человека во время прослушивания музыки [1]. Сравнение некоторых алгоритмов отбора признаков, в том числе и PCA, для распознавания эмоций уже приведено в статье [12], более того, авторы статей [13], [14] рассказывают ещё больше об исследовании данных ЭЭГ. Ряд авторов [15], [16] использует мультимодальные нейронные сети для достижения высокой точности предсказаний (state-of-art). Отдельные исследователи [17] применяют комбинацию качественного отбора признаков и необычного классификатора для повышения точности предсказаний на датасете DEAP. Представленные выше работы тесно связаны и находятся на переднем крае исследований в области анализа EEG данных, что предлагает серьёзную основу для данного исследования.

## 4 Данные и методы

### 4.1 Модули Python

Работа велась с использованием jupyter notebook [18] (далее ноутбук), в который были загружены следующие библиотеки и модули:

1. Pandas – для использования Dataframe, объекта для манипулирования индексированными массивами двумерных данных;
2. Seaborn и Matplotlib – необходимые модули для визуализации данных, построения графиков;
3. Scipy – импортируются функции для работы с данными ЭЭГ и математических преобразований, одна из ключевых функций – `signal.welch`, позволяющая оценивать спектральную плотность сигнала с помощью метода Уэлча [19].
4. Sklearn – включает ключевые инструменты анализа данных, используемые в дальнейшем методы PCA, SVC, k-NN и MLP, а также метрики оценки качества обработки данных и построения классификаторов;
5. MNE – используются модули для визуализации и кросс-валидации.

Все используемые модули, включая стандартные, можно увидеть в секции 1.1. ноутбука.

### 4.2 DEAP - секция 1.2

В проекте используются данные датасета DEAP, предназначенного для распознавания эмоций с использованием данных ЭЭГ, физиологических и видеосигналов. С помощью специальных электродов, эти данные измерялись для 32 участников, каждый из которых посмотрел 40 одноминутных отрывков музыкальных клипов. Также участники оценивали каждый клип с точки зрения уровней возбуждения, валентности, доминирования и знакомства – характеристик важных для распознавания эмоций, более подробно описанных в разделе Модель эмоций.

Стоит отметить, что данные датасета, используемые в проекте, уже прошли первичную обработку, в ходе которой были убраны артефакты и часть шумов. Чтобы получить доступ к данным, необходимо обратиться к авторам датасета на указанном выше сайте. В проект не включены данные датасета в соответствии с соглашением EULA, однако результаты работы можно воспроизвести, загрузив данные `data_preprocessed_python.zip` в папку `project_data`.

Загрузка датасета происходит в секции 1.2. ноутбука. В данном проекте используются только данные с 32 датчиков ЭЭГ, а также шкалы Возбуждения(Arousal) и Валентности(Valence), выделение которых соответствует секциям 2.1. - 2.2. ноутбука.

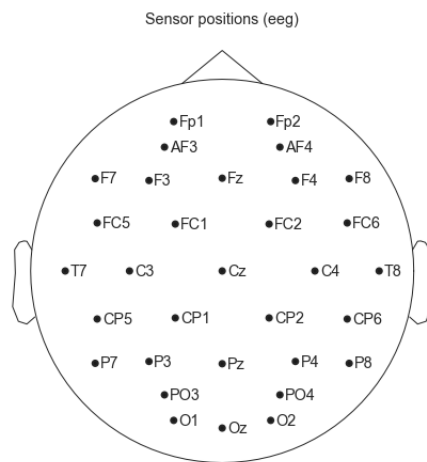


Рис. 1: Расположение датчиков на голове человека

### 4.3 Модель эмоций

Исследование опирается на использование циркумплексной модели эмоций, предложенной Джеймсом Расселом [20]. Модель основывается на распределении эмоций в двумерном круговом пространстве, содержащем измерения возбуждения и валентности. Возбуждение представляет собой вертикальную ось, а валентность представляет собой горизонтальную ось, а центр круга представляет нейтральную валентность и средний уровень возбуждения. Различные чёткие эмоции могут быть нанесены на циркумплекс в соответствии с их уровнями возбуждения и валентности.




Рис. 2: Четкие эмоции на циркумплексе Рассела

В исследовании показатели возбуждения и валентности кодируются бинарно относительно медианы измерений. Таким образом, каждый прослушанный клип имеет бинарный рейтинг по каждой шкале, что позволяет сформировать 4 категории эмоций, соответствующих четвертям циркумплекса:

1. Высокое Возбуждение, Высокая Валентность / High Arousal High Valence (далее HAHV)
2. Низкое Возбуждение, Высокая Валентность / Low Arousal High Valence (далее LAHV)
3. Высокое Возбуждение, Низкая Валентность / High Arousal Low Valence (далее HALV)
4. Низкое Возбуждение, Низкая Валентность / Low Arousal Low Valence (далее LALV)

Эти категории также добавлены в датафрейм и закодированы в секции 2.1. ноутбука, распределение возбуждения и валентности в четвертях циркумплекса можно наблюдать на изображении ниже.




Рис. 3: Распределение Возбуждения(Arousal) и Валентности(Valence) относительно четвертей циркумплекса

## 5 Работа с данными

### 5.1 Извлечение признаков

Как уже было отмечено, в исследовании рассматриваются только данные 32 датчиков ЭЭГ для каждого клипа. В соответствии с этим, для каждого сигнала можно выделить следующие категории признаков:

1. Мощности частотных диапазонов;
2. Статистические характеристики;
3. Параметры Хьюрта [21];
4. Фрактальная размерность.

Опишем введённые параметры.

#### 5.1.1 Мощности частотных диапазонов

Рассмотрим сырые данные из датасета.




Рис. 4: Сигнал

Как можно понять по графику, на протяжении времени измеряется только напряжение. Однако напряжения недостаточно для характеристики мозговых волн, в связи с чем вводится дополнительная характеристика - спектральная плотность мощности. СПМ - функция, описывающая распределение мощности сигнала в зависимости от частоты. Её можно вычислить методом Уэлча[19]. Пример вычисления такой характеристики для отдельного сигнала можно увидеть на изображении ниже.

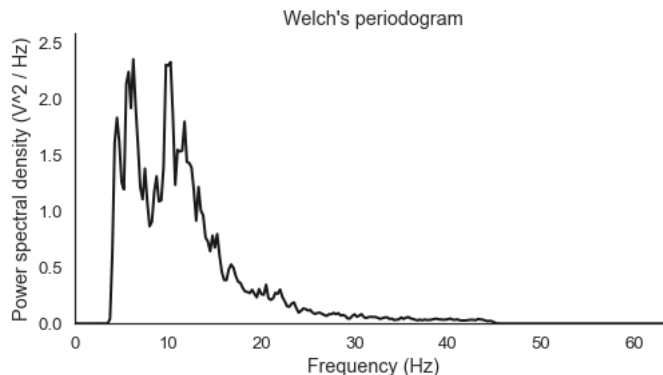


Рис. 5: Периодограмма Уэлча

Однако напрямую данная характеристика в исследовании не будет использоваться, но понадобится для вычисления средней мощности входного сигнала (bandpower), которую мы вычислим для каждого диапазона частот мозга.

При передаче электрических импульсов по нервным волокнам от нейрона к нейрону мозг человека генерирует волны, называемые мозговыми. Они принимают значения от 1 до 70 Гц и выше и подразделяются на следующие категории:

Название диапазона	Принимаемые значения
Дельта-волны	1 - 4 Гц
Тета-волны	4 - 8 Гц
Альфа-волны	8 - 12 Гц
Бета-волны	12 - 30 Гц
Гамма-волны	30 - 70 Гц

Стоит отметить, что датчики не замеряли дельта-волны, а гамма-волны были ограничены сверху в 64 Гц. После разбиения частот на диапазоны для каждого из 4 диапазонов (дельта, тета, альфа и гамма) необходимо вычислить соответствующую мощность сигнала. Вычисление реализовано на основе алгоритма, предложенного Raphael Vallat[22].

### 5.1.2 Статистические характеристики

Изначально предполагалось использование 6 характеристик – функций от массива значений напряжения конкретного электрода: медиана, среднее, максимальное и минимальное значение, стандартное отклонение и коэффициент эксцесса (Куртосис). Однако в ходе работы я ограничился тремя из них:

1. Среднее (арифметическое) – мера центральной тенденции, равная сумме всех чисел множества, делённой на их количество:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \frac{1}{n} (x_1 + \dots + x_n)$$

2. Стандартное отклонение – мера величины вариации или дисперсии набора значений. Определяется как корень из дисперсии случайной величины:

$$\sigma = \sqrt{D[X]}$$

3. Куртосис – мера остроты пика распределения случайной величины. Определяется следующим образом для случайной величины  $X$ , такой что  $\mathbb{E}|X|^4 < \infty$ . Пусть  $\mu_4$  обозначает четвёртый центральный момент  $X$ , а  $\sigma$  – стандартное отклонение  $X$ , тогда куртосис вычисляется как

$$\gamma_2 = \frac{\mu_4}{\sigma^4} - 3$$

### 5.1.3 Параметры Хьюрта

Данные параметры были предложены Бо Хьюртом [21] для исследования данных ЭЭГ, на эти признаки опирались некоторые представленные в библиографии статьи.

1. Активность – представляет мощность сигнала, дисперсию временной функции:

$$\text{Activity} = \text{var}(y(t))$$

2. Мобильность – представляет собой среднюю частоту или долю стандартного отклонения спектра мощности и определяется как квадратный корень из дисперсии первой производной сигнала, деленной на дисперсию сигнала:

$$\text{Mobility} = \sqrt{\frac{\text{var}\left(\frac{dy(t)}{dt}\right)}{\text{var}(y(t))}}$$

3. Сложность – представляет изменение частоты и выражается следующим образом:

$$\text{Complexity} = \frac{\text{Mobility}\left(\frac{dy(t)}{dt}\right)}{\text{Mobility}(y(t))}$$

#### 5.1.4 Фрактальная размерность

Используется параметр фрактальной размерности, предложенный А.Петросяном [23] и вычисляющийся как

$$P = \frac{\log_{10}(N)}{\log_{10}(N) + \log_{10}(\frac{N}{N+0.4N_{\delta}})}$$

где  $N$  – длина сигнала, а  $N_{\delta}$  является числом изменений знака в производной сигнала.

Помимо введённых параметров, в исследованиях ЭЭГ также используются другие характеристики, такие как логарифмические мощности частотных диапазонов[24] и Вейвлет-преобразование[25].

Вычислив параметры в секции 3.1. ноутбука, был получен датафрейм, содержащий 11 характеристик каждого из 32 сигналов, всего 352 признака.

	Theta_01	Alpha_01	Beta_01	Gamma_01	Mean_01	...	Kurtosis_32	Activity_32	Mobility_32	Complexity_32	Fractal dimension_32
0	3.966387	3.362791	5.815234	1.216603	-0.028259	...	0.423327	19.153627	0.550910	1.279431	1.014171
1	5.171664	4.159797	6.395374	1.450174	-0.082712	...	0.636155	23.840406	0.524440	1.312275	1.014451
2	4.839268	4.294426	6.721424	1.541999	0.060689	...	0.917153	26.850180	0.547663	1.260934	1.014610
3	4.442888	3.519818	5.380133	1.280744	-0.027773	...	0.515875	22.089439	0.531993	1.286845	1.014051
4	2.698928	2.770151	4.911636	1.076200	-0.062537	...	0.552951	17.434434	0.568176	1.236513	1.014226

Рис. 6: Фрагмент датафрейма

## 5.2 Классификация

Нас будет интересовать задача классификации клипов по типу вызываемых эмоций. В фокусе внимания находится предсказание возбуждения(высокого или низкого), валентности(высокой или низкой), а также четверти циркумплекса(НАНВ, ЛАНВ, HALV, LALV) в предложенной ранее модели эмоций. Для обработки полученного набора признаков будем разбивать данные на тренировочную и тестовую выборки, а затем проводить Масштабирование признаков(Feature Scaling) как предложено в секции 5.1 ноутбука. Масштабирование признаков помогает нормализовать выборку, что существенно для работы некоторых классификаторов. Далее используем несколько классификаторов, применив подход кросс-валидации с 5-кратной проверкой(kFold=5). В проекте использованы классификаторы SVM, k-NN и MLP.

Будем отслеживать точность предсказаний для 3 признаков, упомянутых выше: Arousal(1, 0), Valence(1, 0) и State(НАНВ, ЛАНВ, HALV, LALV). После описанной процедуры были получены следующие точности(секция 3.2 ноутбука):

- Arousal accuracy: 64.23
- Valence accuracy: 67.48
- State accuracy: 43.9

Несмотря на точность, сопоставимую с результатами статьи[17], с помощью применения PCA можно добиться улучшения точности.

## 5.3 Применение PCA

Как в предыдущем случае, сначала произведём масштабирование признаков (секция 4.1 ноутбука), так как оно существенно для корректной работы алгоритма PCA. Затем напомним функцию, которая будет использовать PCA с заданным числом компонент(секция 4.2 ноутбука). Чтобы вычислить оптимальное число компонент, применим PCA для всех размеров компонент в диапазоне от 2 до 75 (до четверти от исходного количества признаков – 352). После каждого применения PCA применим функцию для измерения точности предсказания с предложенными классификаторами из пункта выше и построим график, сопоставляющий число компонент PCA с точностью предсказаний (секция 5.3 ноутбука).






Рис. 7: Применение PCA для предсказания Arousal, Valence и State

По графику видно, что даже при малом числе компонент можно добиться высокой точности модели. В соответствии с графиком выберем небольшое, оптимальное число компонент и оценим точность предсказаний.

- Arousal prediction accuracy improvement with PCA: 64.23 -> 69.11 . Improvement: + 4.8799999999999955 .
- Valence prediction accuracy improvement with PCA: 67.48 -> 73.17 . Improvement: + 5.6899999999999998 .
- State prediction accuracy improvement with PCA: 43.9 -> 49.59 . Improvement: + 5.6900000000000005 .

Также можно оценить снижение количества компонент

- PCA Arousal accuracy: 69.11 . Components reduction: 352 -> 12
- PCA Valence accuracy: 73.17 . Components reduction: 352 -> 30
- PCA State accuracy: 49.59 . Components reduction: 352 -> 59

## 6 Полученные результаты

### 6.1 Сравнение результатов классификации с использованием PCA - секция 5.4

Рассмотрев полученные результаты(секция 5.4 ноутбука), можно выявить преимущества использования PCA над выборкой перед классификацией. Прежде всего, это многократное сокращение количества признаков, необходимых для точной работы модели. Более того, в результате преобразований были получены такие признаки, что точность модели даже повысилась (в среднем, на 5 процентных пунктов). Это может свидетельствовать о применимости PCA в очистке шума и лишних признаков, которые могли ухудшать качество модели. При исследованиях ЭЭГ как сокращение количества признаков модели, так и очистка шума являются важными задачами. Проведённое исследование демонстрирует эффективность PCA в решении этих задач и доказывает применимость PCA в повышении точности модели и сокращения её веса.

### 6.2 Рассуждения

Тем не менее, существуют другие способы отбора признаков, например, в уже упомянутой статье[17] используется алгоритм Максимальной релевантности - минимальной избыточности / Maximum Relevance — Minimum Redundancy(MRMR) и достигаются аналогичные результаты. Некоторые исследователи используют Анализ независимых компонент / Independent component analysis(ICA) для отбора признаков модели. Более того, на передний план выходит необходимость выявления нелинейных зависимостей признаков[10], для чего PCA неприменима, в связи с чем используются модели, основанные на глубоких нейронных сетях. Использование мультимодальных нейронных сетей было успешно в статьях [15], [16], являющиеся state-of-the-art работами, основанными также на данных DEAP. Все указанные способы отбора признаков отличаются от рассмотренного в исследовании, что позволяет говорить о необходимости выявления наиболее оптимальных подходов в будущем.

## 7 Список литературы

- [1] S. Koelstra, C. Muhl, M. Soleymani, Jong-Seok Lee, A. Yazdani, T. Ebrahimi, T. Pun, A. Nijholt, and I. Patras. Deap: A database for emotion analysis using physiological signals. *IEEE Transactions on Affective Computing*, 3(1):18–31, 2012.

- [2] Deapdataset. <http://www.eecs.qmul.ac.uk/mmv/datasets/deap/>. Accessed: 2022.
- [3] Joseph Newbold, Nadia Bianchi-Berthouze, Nicolas Gold, and Amanda Williams. Musically informed sonification for self-directed chronic pain physical rehabilitation, 06 2015. Conference: Sound and Music Computing 2015.
- [4] Bruno H. Repp. Sensorimotor synchronization: a review of the tapping literature. *Psychonomic Bulletin & Review*, 12(6):969–992, 2005.
- [5] Gisa Aschersleben. Temporal control of movements in sensorimotor synchronization. *Brain and Cognition*, 48(1):66–79, 2002.
- [6] J. Berger D. Siwiak and Y. Yang. Catch your breath-musical biofeed- back for breathing regulation, 2009. Conference: Audio Eng. Society Conv 2009.
- [7] S. Koelsch. *Brain and Music*, pages 179–180. Wiley, 2012.
- [8] Grace Leslie, Asma Ghandeharioun, Diane Y. Zhou, and Rosalind W. Picard. Engineering music to slow breathing and invite relaxed physiology. *2019 8th International Conference on Affective Computing and Intelligent Interaction (ACII)*, pages 1–7, 2019.
- [9] Endel. Endel: Personalized soundscapes to help you focus, relax, and sleep. backed by neuroscience., n.d. Accessed Feb 10, 2022.
- [10] Xiao-Wei Wang, Dan Nie, and Bao-Liang Lu. Emotional state classification from eeg data using machine learning approach. *Neurocomputing*, 129:94–106, 2014.
- [11] Warren B Powell. Approximate dynamic programming : solving the curses of dimensionality, 2011.
- [12] Rab Nawaz, Kit Hwa Cheah, Humaira Nisar, and Vooi Voon Yap. Comparison of different feature extraction methods for eeg-based emotion recognition. *Biocybernetics and Biomedical Engineering*, 40(3):910–926, 2020.
- [13] Avinash L. Tandle, Manjusha S. Joshi, Ambrish S. Dharmadhikari, and Suyog V. Jaiswal. Mental state and emotion detection from musically stimulated eeg. *Brain Informatics*, 5(2):14, 2018.
- [14] Klaus Scherer. Which emotions can be induced by music? what are the underlying mechanisms? and how can we measure them? *Journal of New Music Research*, 33:239–251, 09 2004.
- [15] Yuxuan Zhao, Xinyan Cao, Jinlong Lin, Dunshan Yu, and Xixin Cao. Multimodal emotion recognition model using physiological signals. *ArXiv*, abs/1911.12918, 2019.
- [16] Wei Liu, Wei-Long Zheng, and Bao-Liang Lu. Multimodal emotion recognition using multimodal deep learning, 02 2016.
- [17] John Atkinson-Abutridy and Daniel Campos. Improving bci-based emotion recognition by combining eeg feature selection and kernel classifiers. *Expert Systems with Applications*, 47, 11 2015.
- [18] Jupyter notebook. <https://jupyter.org/>. Accessed: 2022.
- [19] P. Welch. The use of fast fourier transform for the estimation of power spectra: A method based on time averaging over short, modified periodograms. *IEEE Transactions on Audio and Electroacoustics*, 15(2):70–73, 1967.
- [20] James Russell. A circumplex model of affect. *Journal of Personality and Social Psychology*, 39:1161–1178, 12 1980.
- [21] Bo Hjorth. EEG analysis based on time domain properties. *Electroencephalography and Clinical Neurophysiology*, 29(3):306–310, 1970.
- [22] Compute the average bandpower of an eeg signal. <https://raphaelvallat.com/bandpower>. Accessed: 2022.
- [23] Arthur A. Petrosian. Kolmogorov complexity of finite sequences and recognition of different preictal eeg patterns. *Proceedings Eighth IEEE Symposium on Computer-Based Medical Systems*, pages 212–217, 1995.

- [24] Clemens Brunner, Martin Billinger, Carmen Vidaurre, and Christa Neuper. A comparison of univariate, vector, bilinear autoregressive, and band power features for brain–computer interfaces. *Medical biological engineering computing*, 49:1337–46, 09 2011.
- [25] Panagiotis Petrantonakis and Leontios Hadjileontiadis. Emotion recognition from brain signals using hybrid adaptive filtering and higher order crossings analysis. *Affective Computing, IEEE Transactions on*, 1:81–97, 07 2010.

## Приложение А. Календарный план работ

Этап работы	Предполагаемые даты
КТ1. Загрузка исправленного с учетом замечаний Отчета с подписанным студентом титульным листом	Не позднее 17.02.22
КТ1. Оценивание результатов и передача оценки в ЦППРиП	Не позднее 22.02.22
Представление результатов выполнения Проекта руководителю	Не позднее, чем за 10 рабочих дней до даты защиты
Подготовка и представление руководителю итогового варианта результатов Проекта	Не позднее, чем за 6 рабочих дней до даты защиты
Загрузка итогового варианта Проекта в SmartLMS/LMS для проверки работы в системе «Антиплагиат»	Не позднее, чем за 6 рабочих дней до даты защиты
Отзыв руководителя	Не позднее, чем за 3 рабочих дня до даты защиты
Загрузка в Задание дисциплины «Программный проект для студентов 2 курса ПМИ» в SmartLMS итогового варианта Проекта, отзыва руководителя, отчета системы “Антиплагиат”, других необходимых материалов	Не позднее, чем за 3 рабочих дня до даты защиты
Публичная защита Проекта	Согласно утвержденному графику